# มหาวิทยาลัยธุรกิจบัณฑิตย์

ข้อสอบวิชา วิทยาศาสตร์ข้อมูลและการวิเคราะห์ข้อมูลขนาดใหญ่ รหัสวิชา DT514

จำนวน 3 หน่วยกิต

ระดับ ☐ ปริญญาตรี ☑ บัณฑิตศึกษา

รอบเวลาเรียน ☑ ภาคปกติ ☐ ภาคค่ำ/ภาคพิเศษ

วิทยาลัยครีเอทีฟดีไซน์แอนด์เอ็นเตอร์เทนเมนต์เทคโนโลยี

หลักสูตรเทคโนโลยีดิจิทัลเชิงกลยุทธ์

สอบกลางภาค ประจำภาคการศึกษาที่ 1 ปีการศึกษา 2569

อาจารย์ผู้สอน ผศ.ดร.เจษฎา ขจรฤทธิ์

**ข้อกำหนด**

1. ข้อสอบมี 2 ตอน คะแนนรวม 40 คะแนน
2. การนำตำรา หนังสือ หรือเอกสารเข้าห้องสอบ
   - ตำราหรือหนังสือ ☑ ให้ ☐ ไม่ให้
   - เอกสาร A4 ☑ ให้ ☐ ไม่ให้
3. การใช้เครื่องคอมพิวเตอร์ ☑ ให้ ☐ ไม่ให้
4. การใช้ปัญญาประดิษฐ์ ☑ ให้ ☐ ไม่ให้

**คำสั่ง**

ให้ทำข้อสอบดังนี้

- ส่วนที่ 1: Feature Engineering (20 คะแนน)
- ส่วนที่ 2: Classification Modeling (20 คะแนน)

วิธีการสอบ

- ใช้ข้อมูลจากไฟล์ “heart.csv”
- ใช้ Jupyter Notebook หรือเครื่องมืออื่นๆ ในการหาคำตอบ
- นำเสนอผลลัพธ์ในรูปแบบ Jupyter Notebook และ Excel

## ส่วนที่ 1: Feature Engineering

1. (5 คะแนน) Observe the dataset
    - (2 คะแนน) ตรวจสอบโครงสร้างและขนาดของชุดข้อมูล
    - (2 คะแนน) ตรวจสอบจำนวนระเบียน จำนวนตัวแปร และชนิดข้อมูลของแต่ละตัวแปร
    - (1 คะแนน) ตรวจสอบและจัดการข้อมูลที่สูญหาย (Missing Values)

2. (5 คะแนน) Preprocess numeric data
    - (1 คะแนน) ระบุตัวแปรที่เป็นข้อมูลตัวเลข
    - (4 คะแนน) เลือกและดำเนินการเตรียมข้อมูลตัวเลขด้วยวิธีที่เหมาะสม

3. (5 คะแนน) Preprocess categorical data
    - (1 คะแนน) ระบุตัวแปรที่เป็นข้อมูลประเภทหมวดหมู่
    - (4 คะแนน) เลือกและดำเนินการแปลงข้อมูลหมวดหมู่ให้อยู่ในรูปแบบตัวเลขด้วยวิธีที่เหมาะสม

4. (5 คะแนน) Separate all data to Training data and Test data
    - (2 คะแนน) แยกตัวแปรอิสระ (Features) ออกจากตัวแปรเป้าหมาย (Target)
    - (2 คะแนน) แบ่งข้อมูลเป็นชุดฝึกสอน (Training Set) และชุดทดสอบ (Test Set) ด้วยสัดส่วนที่เหมาะสม
    - (1 คะแนน) กำหนด random_state เพื่อให้สามารถทำซ้ำการทดลองได้

## ส่วนที่ 2: Classification Modeling

5. (5 คะแนน) Decision Tree
    - (3 คะแนน) สร้างและฝึกสอนแบบจำลอง Decision Tree ด้วยชุดข้อมูลฝึกสอน
    - (2 คะแนน) ประเมินประสิทธิภาพของแบบจำลองด้วยชุดข้อมูลทดสอบ

6. (5 คะแนน) Random Forest
    - (3 คะแนน) สร้างและฝึกสอนแบบจำลอง Random Forest ด้วยชุดข้อมูลฝึกสอน
    - (2 คะแนน) ประเมินประสิทธิภาพของแบบจำลองด้วยชุดข้อมูลทดสอบ

7. (5 คะแนน) Gradient Boost Trees
    - (3 คะแนน) สร้างและฝึกสอนแบบจำลอง Gradient Boost Tree ด้วยชุดข้อมูลฝึกสอน
    - (2 คะแนน) ประเมินประสิทธิภาพของแบบจำลองด้วยชุดข้อมูลทดสอบ

8. (5 คะแนน) Model Comparison and Selection
    - (3 คะแนน) เปรียบเทียบประสิทธิภาพของแบบจำลองทั้ง 3 วิธีด้วยตัวชี้วัดที่เหมาะสม
    - (2 คะแนน) เลือกแบบจำลองที่มีประสิทธิภาพดีที่สุด พร้อมอธิบายเหตุผลประกอบการตัดสินใจ