มหาวิทยาลัยธุรกิจบัณฑิตย์

ข้อสอบวิชา วิทยาศาสตร์ข้อมูลและการวิเคราะห์ข้อมูลขนาดใหญ่ รหัสวิชา DT514

จำนวน 3 หน่วยกิต

ระดับ ☐ ปริญญาตรี ☑ บัณฑิตศึกษา

รอบเวลาเรียน ☑ ภาคปกติ ☐ ภาคค่ำ/ภาคพิเศษ

วิทยาลัยครีเอทีฟดีไซน์แอนด์เอ็นเตอร์เทนเมนต์เทคโนโลยี

หลักสูตรเทคโนโลยีดิจิทัลเชิงกลยุทธ์

สอบกลางภาค ประจำภาคการศึกษาที่ 1 ปีการศึกษา 2569

อาจารย์ผู้สอน ผศ.ดร.เจษฎา ขจรฤทธิ์

ข้อกำหนด

1. ข้อสอบมี 2 ตอน คะแนนรวม 40 คะแนน
2. การนำตำรา หนังสือ หรือเอกสารเข้าห้องสอบ
   - ตำราหรือหนังสือ ☑ ให้ ☐ ไม่ให้
   - เอกสาร A4 ☑ ให้ ☐ ไม่ให้
3. การใช้เครื่องคอมพิวเตอร์ ☑ ให้ ☐ ไม่ให้
4. การใช้ปัญญาประดิษฐ์ ☑ ให้ ☐ ไม่ให้

คำสั่ง

ให้เลือกทำข้อสอบดังนี้

- ส่วนที่ 1: เลือกทำ 5 ข้อ จากข้อสอบ Exploratory Data Analysis (ข้อ 1–10)
- ส่วนที่ 2: ทำ ทุกข้อ จาก Hypothesis-Based EDA (ข้อ 11–15)

วิธีการสอบ

- ใช้ข้อมูลจากไฟล์ “bank-full.csv” และ “bank-nameห.txt”
- ใช้ Jupyter Notebook หรือเครื่องมืออื่นๆ ในการหาคำตอบ
- นำเสนอผลลัพธ์ในรูปแบบ PowerPoint โดยจัดทำ 1 ข้อ / 1 สไลด์

ข้อแนะนำ

- การนำเสนอควรอยู่ในลักษณะของ storytelling โดยใช้ข้อมูลหรือกราฟสนับสนุน และออกแบบ PowerPoint ให้สวยงาม เข้าใจง่าย และสื่อสารชัดเจน
- จุดประสงค์ของข้อสอบคือต้องการให้นำเสนอผลการวิเคราะห์อย่างมีเหตุผล มีความต่อเนื่องทางตรรกะ ซึ่งเป็นสิ่งสำคัญมากกว่าคำตอบสุดท้าย

ส่วนที่ 1: Exploratory Data Analysis

1. (4 คะแนน) Distribution of Duration
จงวิเคราะห์การกระจายของตัวแปร duration โดยใช้ histogram และ boxplot พร้อมอธิบายว่ามี skewness หรือ outliers หรือไม่

2. (4 คะแนน) Duration vs Target
จงเปรียบเทียบ distribution ของ duration ระหว่างกลุ่มที่สมัคร (y = yes) และไม่สมัคร (y = no) โดยใช้ boxplot หรือ violin plot พร้อมสรุป insight

3. (4 คะแนน) Categorical Variables Exploration
จงวิเคราะห์ตัวแปร categorical ได้แก่ job, marital, และ education โดยใช้ countplot และ barplot พร้อมอธิบายว่ากลุ่มใดมีแนวโน้มสมัคร term deposit สูงกว่าค่าเฉลี่ย

4. (4 คะแนน) Correlation Matrix
จงสร้าง correlation matrix สำหรับตัวแปร numeric (age, balance, campaign, pdays, previous, duration) และแสดงด้วย heatmap พร้อมตีความความสัมพันธ์ที่สำคัญ

5. (4 คะแนน) Temporal Pattern Analysis
จงวิเคราะห์ผลลัพธ์การสมัคร (y) ตาม month และ day โดยใช้ lineplot หรือ barplot พร้อมอธิบายว่ามี seasonality หรือช่วงเวลาที่ลูกค้าตอบรับมากเป็นพิเศษหรือไม่

6. (4 คะแนน) Balance Distribution
จงวิเคราะห์การกระจายของ balance โดยใช้ histogram และ boxplot พร้อมอธิบายว่าลูกค้าที่มี balance สูงหรือต่ำมีแนวโน้มสมัคร term deposit หรือไม่

7. (4 คะแนน) Loan & Housing Loan Analysis
จงตรวจสอบความสัมพันธ์ระหว่างการมี housing loan และ personal loan กับการสมัคร term deposit โดยใช้ stacked barplot หรือ crosstab heatmap พร้อมสรุป insight

8. (4 คะแนน) Job Category Impact
จงวิเคราะห์ว่าอาชีพใด (job) มีอัตราการสมัคร term deposit สูงสุด โดยใช้ barplot แสดง proportion ของ "yes" ต่อ "no" พร้อมอธิบายผลที่ได้

9. (4 คะแนน) Campaign Effectiveness
จงวิเคราะห์ความสัมพันธ์ระหว่างจำนวนครั้งที่ติดต่อ (campaign) กับการสมัคร term deposit โดยใช้ scatterplot หรือ boxplot พร้อมอธิบายว่าการติดต่อหลายครั้งช่วยเพิ่มโอกาสสมัครหรือไม่

10. (4 คะแนน) Previous Outcome Influence
จงวิเคราะห์ผลลัพธ์ของแคมเปญก่อนหน้า (poutcome) ต่อการสมัครในปัจจุบัน โดยใช้ barplot เปรียบเทียบอัตราการสมัครในแต่ละ category (success, failure, other, unknown) พร้อมสรุป insight

ส่วนที่ 2: Hypothesis-Based EDA

11. (4 คะแนน) Duration Effect
สมมุติฐาน: ลูกค้าที่ใช้เวลาในการสนทนา (duration) นานกว่าจะมีแนวโน้มสมัคร term deposit มากกว่า
ข้อพิสูจน์: จงสร้าง boxplot หรือ histogram ของ duration แยกตาม y (yes/no) แล้วอธิบายว่าข้อสงสัยนี้มีแนวโน้มจริงหรือไม่

12. (4 คะแนน) Education Impact
สมมุติฐาน: ลูกค้าที่มีการศึกษาระดับ tertiary มีแนวโน้มสมัคร term deposit มากกว่ากลุ่มอื่น
ข้อพิสูจน์: barplot แสดง proportion ของการสมัคร (y = yes) ในแต่ละระดับการศึกษา และอธิบายว่าข้อสงสัยนี้สอดคล้องกับข้อมูลหรือไม่

13. (4 คะแนน) Loan Constraint
สมมุติฐาน: ลูกค้าที่มี personal loan (loan = yes) จะมีแนวโน้มสมัคร term deposit น้อยกว่าลูกค้าที่ไม่มี loan
ข้อพิสูจน์: จงสร้าง stacked barplot หรือ crosstab table เปรียบเทียบการสมัคร (y) ระหว่างกลุ่มที่มี loan และไม่มี loan พร้อมอธิบายว่าข้อสงสัยนี้มีแนวโน้มจริงหรือไม่

14. (4 คะแนน) Contact Method Effect
สมมุติฐาน: ลูกค้าที่ถูกติดต่อผ่าน cellular มีแนวโน้มสมัคร term deposit มากกว่าลูกค้าที่ถูกติดต่อผ่าน telephone
ข้อพิสูจน์: จงสร้าง barplot เปรียบเทียบ proportion ของการสมัคร (y = yes) ระหว่าง contact = cellular และ contact = telephone อธิบายว่าข้อสงสัยนี้สอดคล้องกับข้อมูลจริงหรือไม่

15. (4 คะแนน) Campaign Timing Effect
สมมุติฐาน: ลูกค้าที่ถูกติดต่อในช่วงต้นแคมเปญ (จำนวนครั้งที่ติดต่อ campaign น้อย) มีแนวโน้มสมัคร term deposit มากกว่าลูกค้าที่ถูกติดต่อหลายครั้ง
ข้อพิสูจน์: จงสร้าง boxplot หรือ scatterplot แสดงความสัมพันธ์ระหว่างจำนวนครั้งที่ติดต่อ (campaign) และการสมัคร (y) อธิบายว่าข้อสงสัยนี้มีแนวโน้มจริงหรือไม่จากข้อมูล